


ALÉM DA LINEARIDADE

FLÁVIA MORAES

MESTRE ECONOMIA, FGV-RJ



1. Introdução

2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



Por que todo mundo

AMA

Regressões Lineares?

1. Introdução

2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models

1. Introdução

2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução

2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



1. Introdução

2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



Regressões
Lineares são

Intuitivas

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



Regressões
Lineares são

Intuitivas

Fáceis de Interpretar

1. Introdução

2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



Regressões
Lineares são

Intuitivas

Fáceis de Interpretar

Boas Inferências

1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



E se...

1. Introdução


2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



a hipótese de linearidade...

1. Introdução

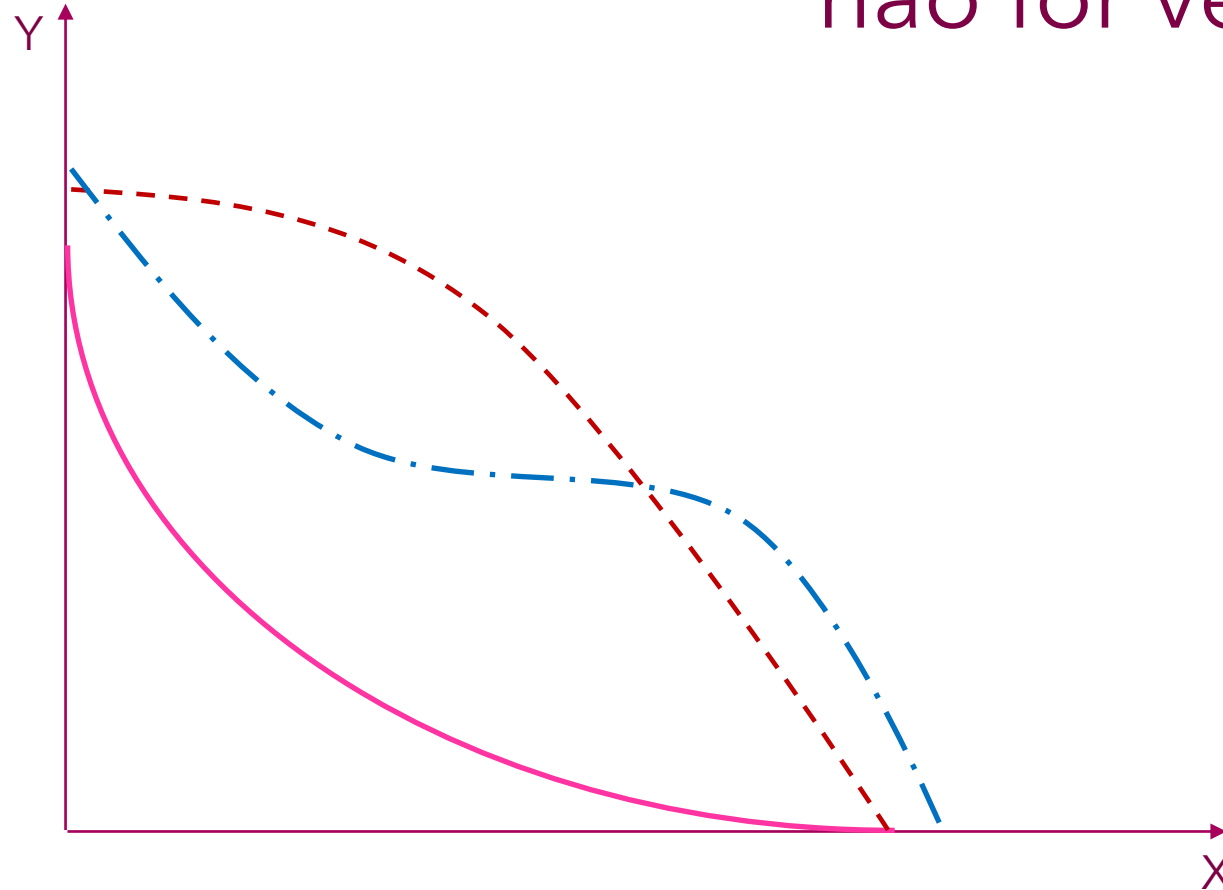
2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models



não for verdadeira????

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models



1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Uma primeira forma de flexibilizar a hipótese de linearidade é acrescentando fatores que são a variável explicativa elevada a uma potência.

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Por exemplo, uma regressão
cúbica usa três variáveis x , x^2 e
 x^3 .*

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \varepsilon_i$$

onde ε_i é o erro.

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*No limite, uma função polinomial de grau **d** pode ser definida como*

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_d x_i^d + \varepsilon_i \quad (7.1)$$

onde ε_i é o erro.

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Note que os coeficientes da equação (7.1) podem ser facilmente estimados usando o Método dos Mínimos Quadrados da Regressão Linear, pois temos um modelo linear simples cujos fatores são $x_i, x_i^2, x_i^3, \dots, x_i^d$.

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models



1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models

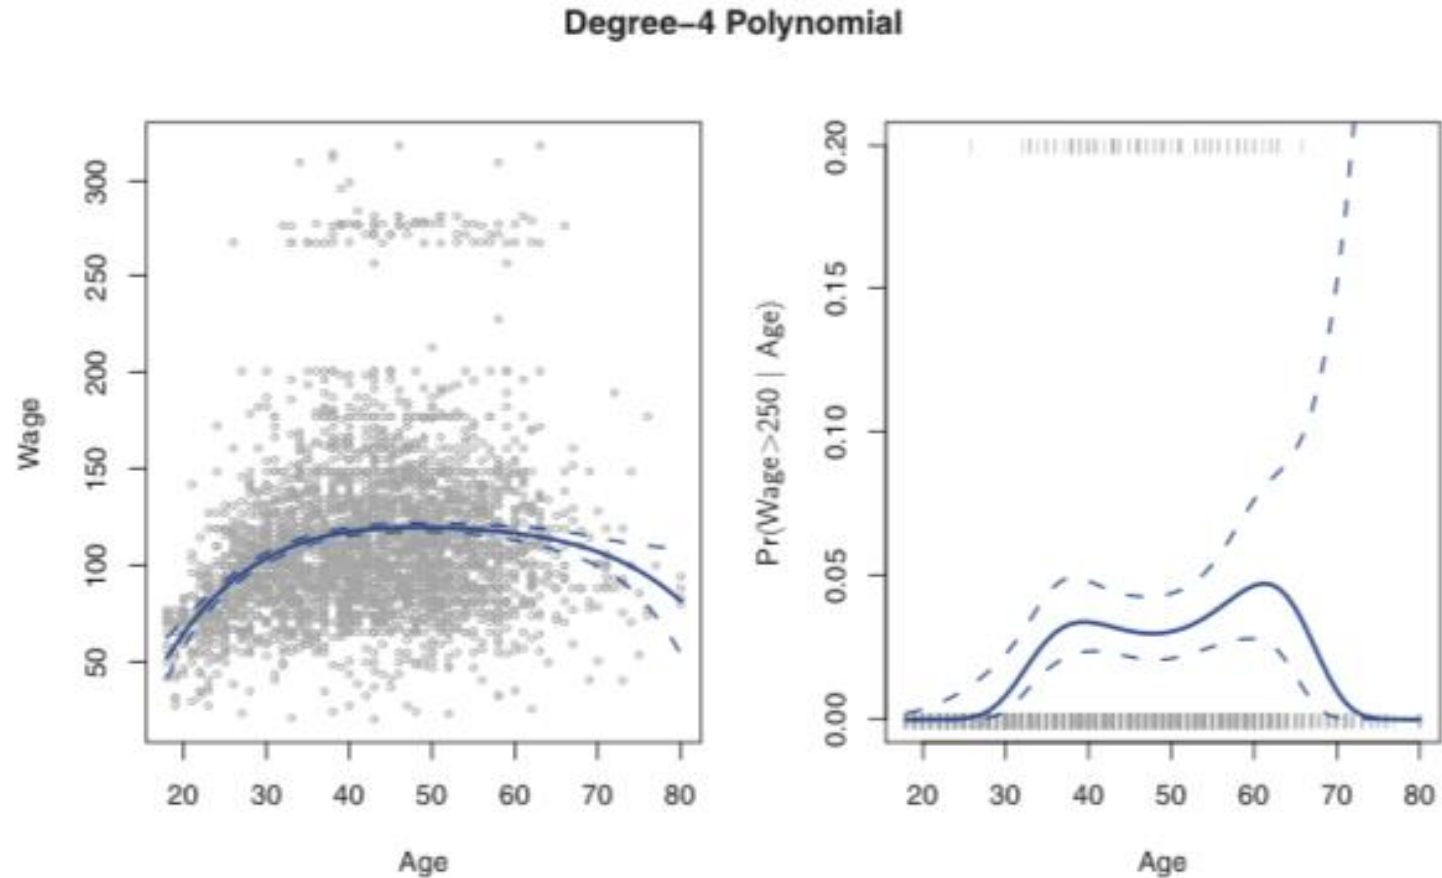


FIGURE 7.1. The *Wage* data. Left: The solid blue curve is a degree-4 polynomial of *wage* (in thousands of dollars) as a function of *age*, fit by least squares. The dotted curves indicate an estimated 95 % confidence interval. Right: We model the binary event *wage* > 250 using logistic regression, again with a degree-4 polynomial. The fitted posterior probability of *wage* exceeding \$250,000 is shown in blue, along with an estimated 95 % confidence interval.

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models

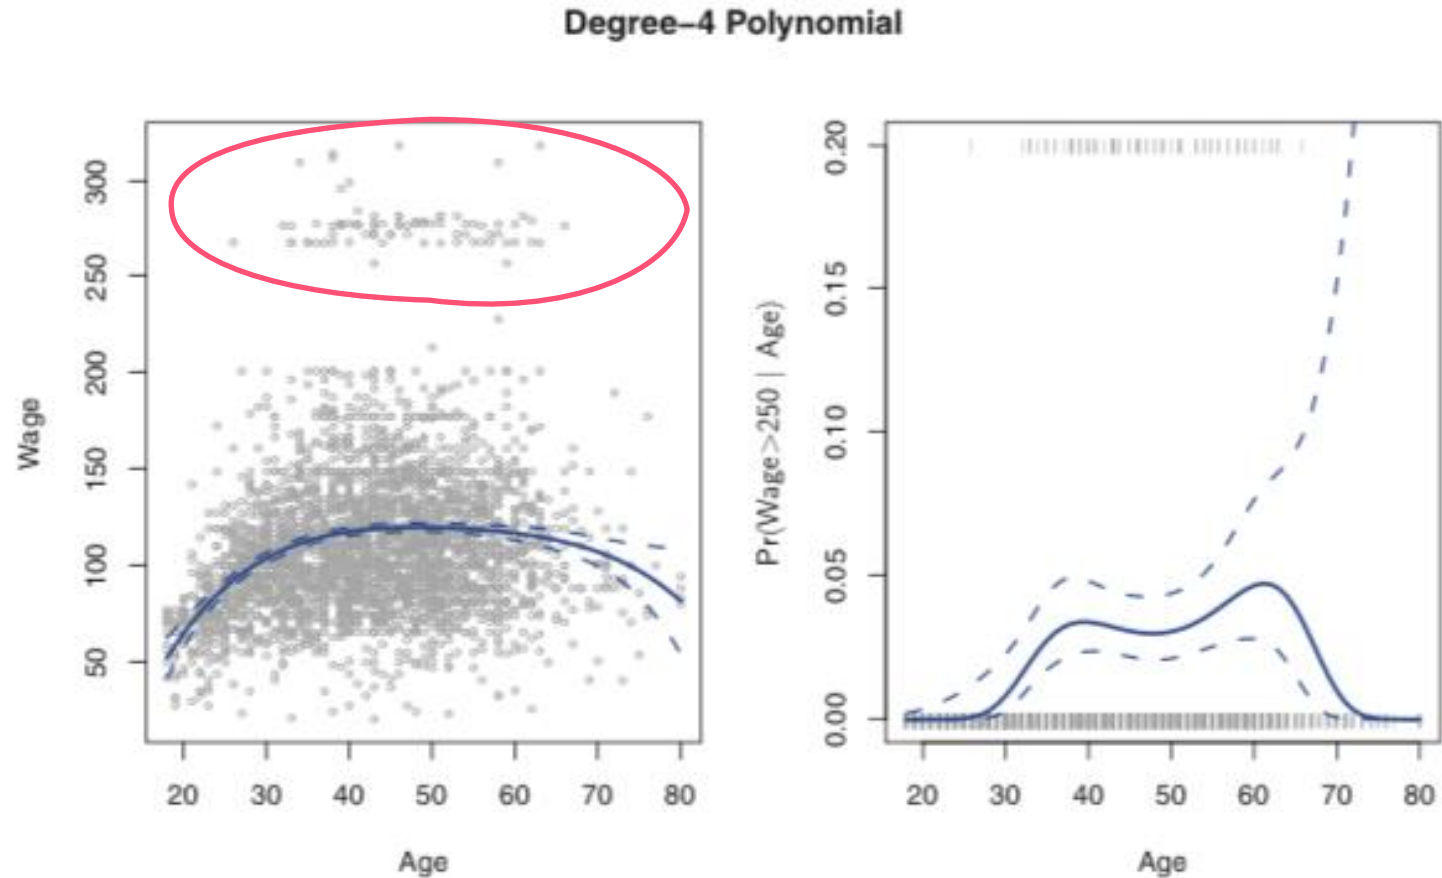


FIGURE 7.1. The *Wage* data. Left: The solid blue curve is a degree-4 polynomial of *wage* (in thousands of dollars) as a function of *age*, fit by least squares. The dotted curves indicate an estimated 95 % confidence interval. Right: We model the binary event *wage* > 250 using logistic regression, again with a degree-4 polynomial. The fitted posterior probability of *wage* exceeding \$250,000 is shown in blue, along with an estimated 95 % confidence interval.

1. Introdução

2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models

Aparentemente existem duas populações:

- remuneração **alta** ($>250k$)
- remuneração **baixa** ($<250k$)

$$\Pr(y_i > 250 | x_i) = \frac{\exp(\beta_0 + \beta_1 x_i + \beta_3 x_i^3 + \dots + \beta_d x_i^d)}{1 + \exp(\beta_0 + \beta_1 x_i + \beta_3 x_i^3 + \dots + \beta_d x_i^d)}$$

1. Introdução

2. Regressão Polinomial

3. Step Functions

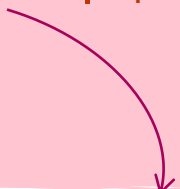
4. Splines

5. Local Regression

6. Generalize Additive Models

Aparentemente existem duas populações:

- remuneração **alta** ($>250k$)
- remuneração **baixa** ($<250k$)

$$\Pr(y_i > 250 | x_i) = \frac{\exp(\beta_0 + \beta_1 x_i + \beta_3 x_i^3 + \dots + \beta_d x_i^d)}{1 + \exp(\beta_0 + \beta_1 x_i + \beta_3 x_i^3 + \dots + \beta_d x_i^d)}$$


1. Introdução

2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models

Aparentemente existem duas populações:

- remuneração **alta** ($>250k$)
- remuneração **baixa** ($<250k$)

$$\Pr(y_i > 250 | x_i) = \frac{\exp(\beta_0 + \beta_1 x_i + \beta_3 x_i^3 + \dots + \beta_d x_i^d)}{1 + \exp(\beta_0 + \beta_1 x_i + \beta_3 x_i^3 + \dots + \beta_d x_i^d)} \quad (7.3)$$

Logistic Regression

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models

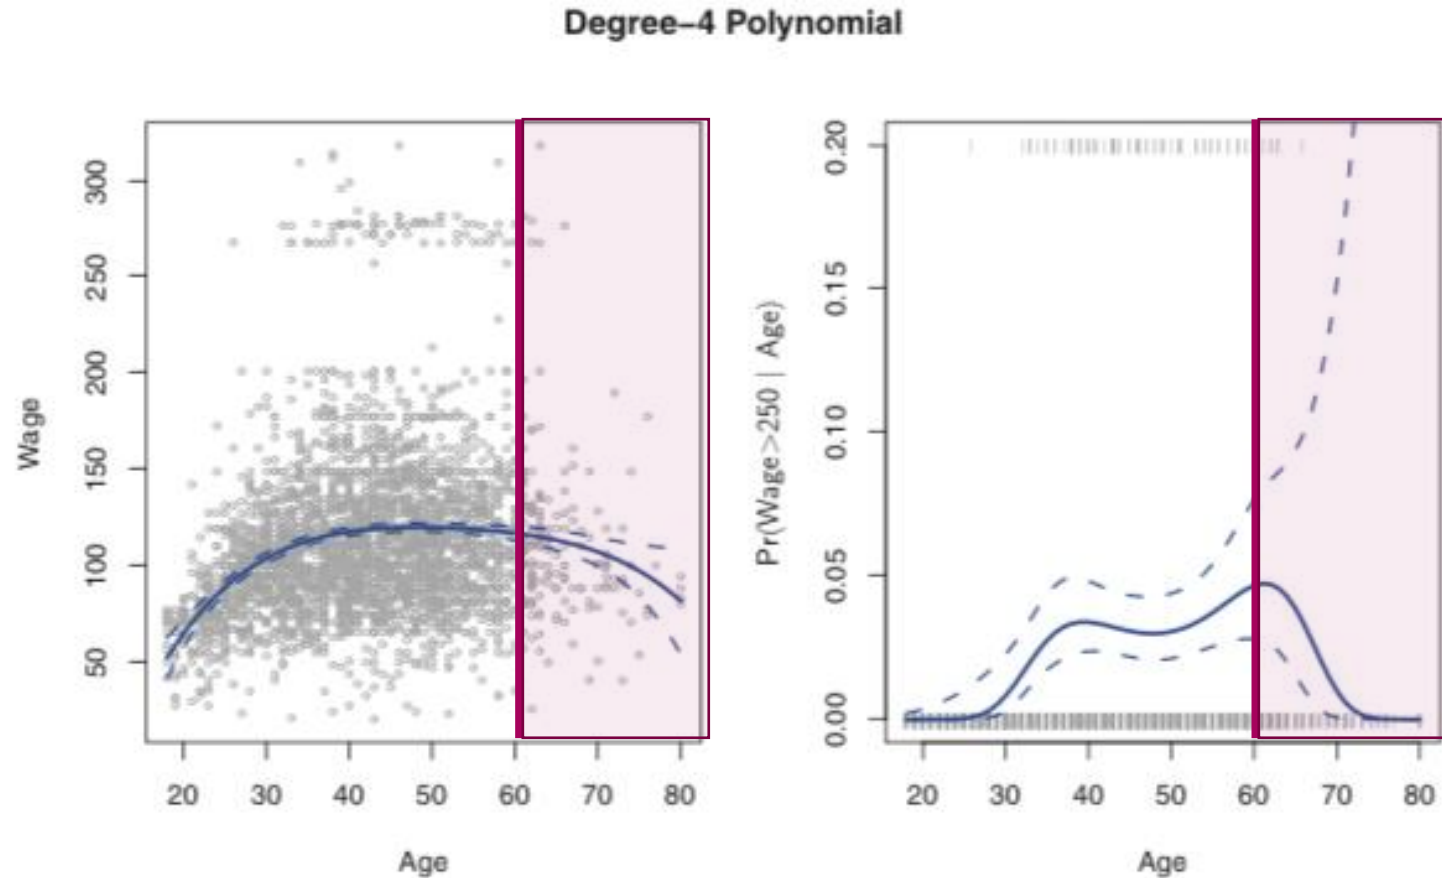


FIGURE 7.1. The **Wage** data. Left: The solid blue curve is a degree-4 polynomial of **wage** (in thousands of dollars) as a function of **age**, fit by least squares. The dotted curves indicate an estimated 95 % confidence interval. Right: We model the binary event **wage**>250 using logistic regression, again with a degree-4 polynomial. The fitted posterior probability of **wage** exceeding \$250,000 is shown in blue, along with an estimated 95 % confidence interval.

1. Introdução

2. Regressão
Polinomial

3. Step
Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models

Podemos converter a variável contínua X em k variáveis categóricas ordenadas, quebrando o intervalo de X em vários compartimentos. Para cada nível, calcularemos um parâmetro β_k .

1. Introdução

2. Regressão
Polinomial

3. Step
Functions

4. Splines

5. Local Regression


6. Generilize
Additive Models

Exemplo:

Vamos pegar o intervalo de 0 a 10 e definir 4 pontos de corte que vão determinar 5 intervalos.

$C_1 = I(X < 2)$ \longrightarrow 1º intervalo

Se x estiver no primeiro intervalo, C_1 vai assumir o valor de 1 e todos demais assumirão o valor zero



1. Introdução

2. Regressão
Polinomial

3. Step
Functions


4. Splines

5. Local Regression

6. Generilize
Additive Models

Exemplo:

Se x estiver no segundo intervalo, C_2 vai assumir o valor de 1 e todos demais assumirão o valor zero



1. Introdução

2. Regressão
Polinomial

3. Step
Functions

4. Splines


5. Local Regression

6. Generilize
Additive Models

Exemplo:

Se x estiver no terceiro intervalo, C_3 vai assumir o valor de 1 e todos demais assumirão o valor zero

$C_3 = 1 \ (4 \leq X < 6)$ \longrightarrow 3º intervalo



1. Introdução

2. Regressão
Polinomial

3. Step
Functions

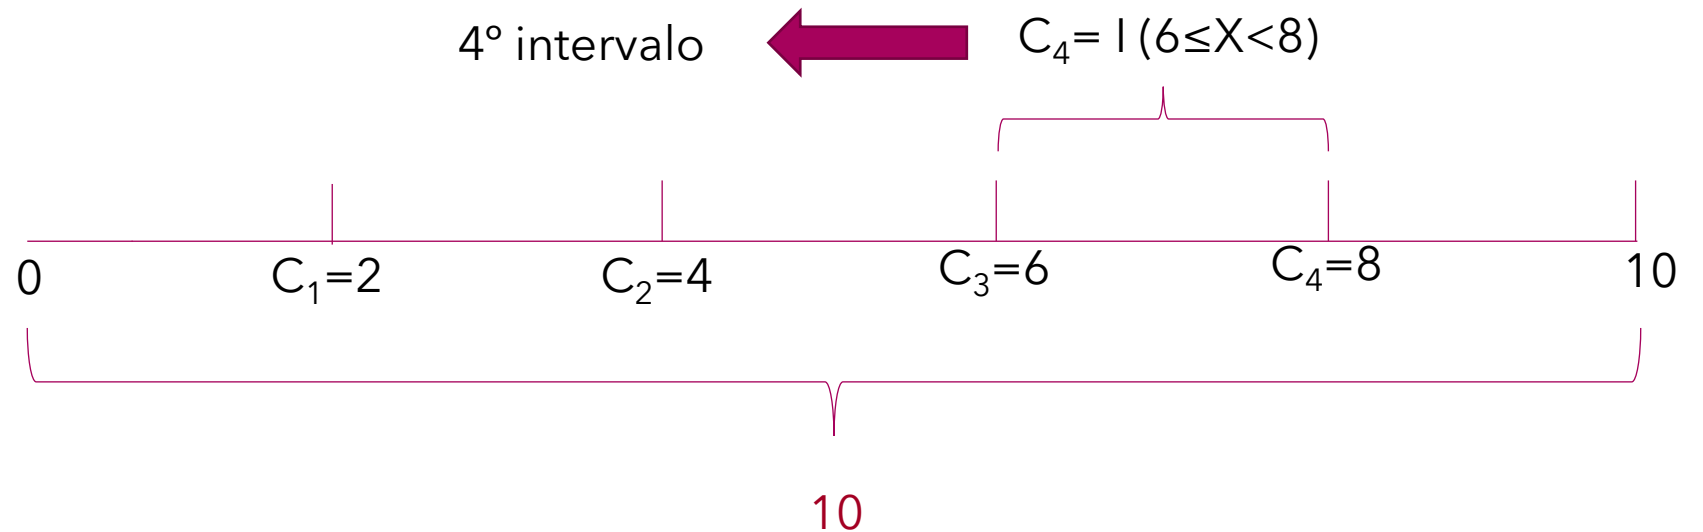
4. Splines

5. Local Regression

6. Generilize
Additive Models

Exemplo:

Se x estiver no primeiro
intervalo, C_4 vai assumir o
valor de 1 e todos demais
assumirão o valor zero



1. Introdução

2. Regressão
Polinomial

3. Step
Functions

4. Splines


5. Local Regression

6. Generilize
Additive Models

Exemplo:

Se x estiver no primeiro intervalo, C_5 vai assumir o valor de 1 e todos demais assumirão o valor zero

5º intervalo ← $C_5 = 1$ ($8 \leq X < 10$)



1. Introdução

2. Regressão
Polinomial

3. Step
Functions


4. Splines

5. Local Regression

6. Generilize
Additive Models

Podemos, portanto, definir k pontos de corte no intervalo X , criando $(k+1)$ variáveis de nível (dummy variables).

$$C_0(X) = I(X \leq c_1) \quad \rightarrow \quad C_1(X) = I(c_1 \leq X < c_2)$$



1. Introdução

2. Regressão
Polinomial

3. Step
Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Vamos então estimar pelo Método dos Mínimos Quadrados uma constante para cada intervalo (ou nível) de X , segundo a equação

$$y_i = \beta_0 + \beta_1 C_1(x_i) + \beta_2 C_2(x_i) + \dots + \beta_k C_k(x_i) + \varepsilon_i \quad (7.5)$$

Onde, para cada valor de x , no máximo um dos C_1, C_2, \dots, C_k pode ser não-nulo.

1. Introdução

2. Regressão
Polinomial

3. Step
Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models



Note que
(1) O valor de β_j representa o acréscimo médio na variável y quando x assume o valor dentro do intervalo j ;
(2) Quando forçamos um valor constante dentro dos intervalos, podemos perder tendências importantes

1. Introdução

2. Regressão
Polinomial

3. Step
Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models

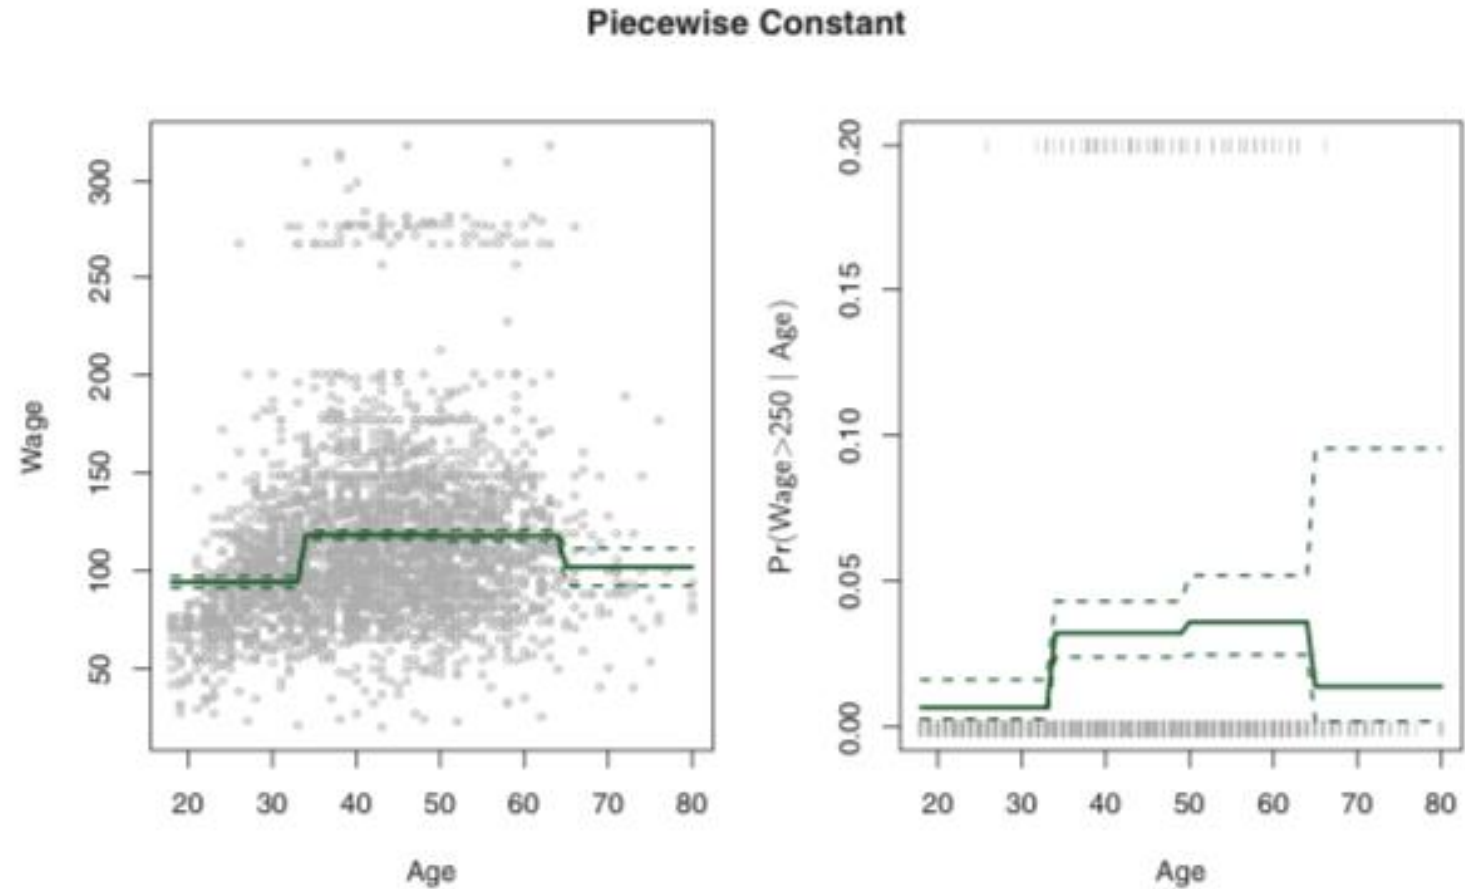


FIGURE 7.2. The *Wage* data. Left: The solid curve displays the fitted value from a least squares regression of *wage* (in thousands of dollars) using step functions of *age*. The dotted curves indicate an estimated 95 % confidence interval. Right: We model the binary event *wage* > 250 using logistic regression, again using step functions of *age*. The fitted posterior probability of *wage* exceeding \$250,000 is shown, along with an estimated 95 % confidence interval.

1. Introdução

2. Regressão
Polinomial

3. Step
Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models

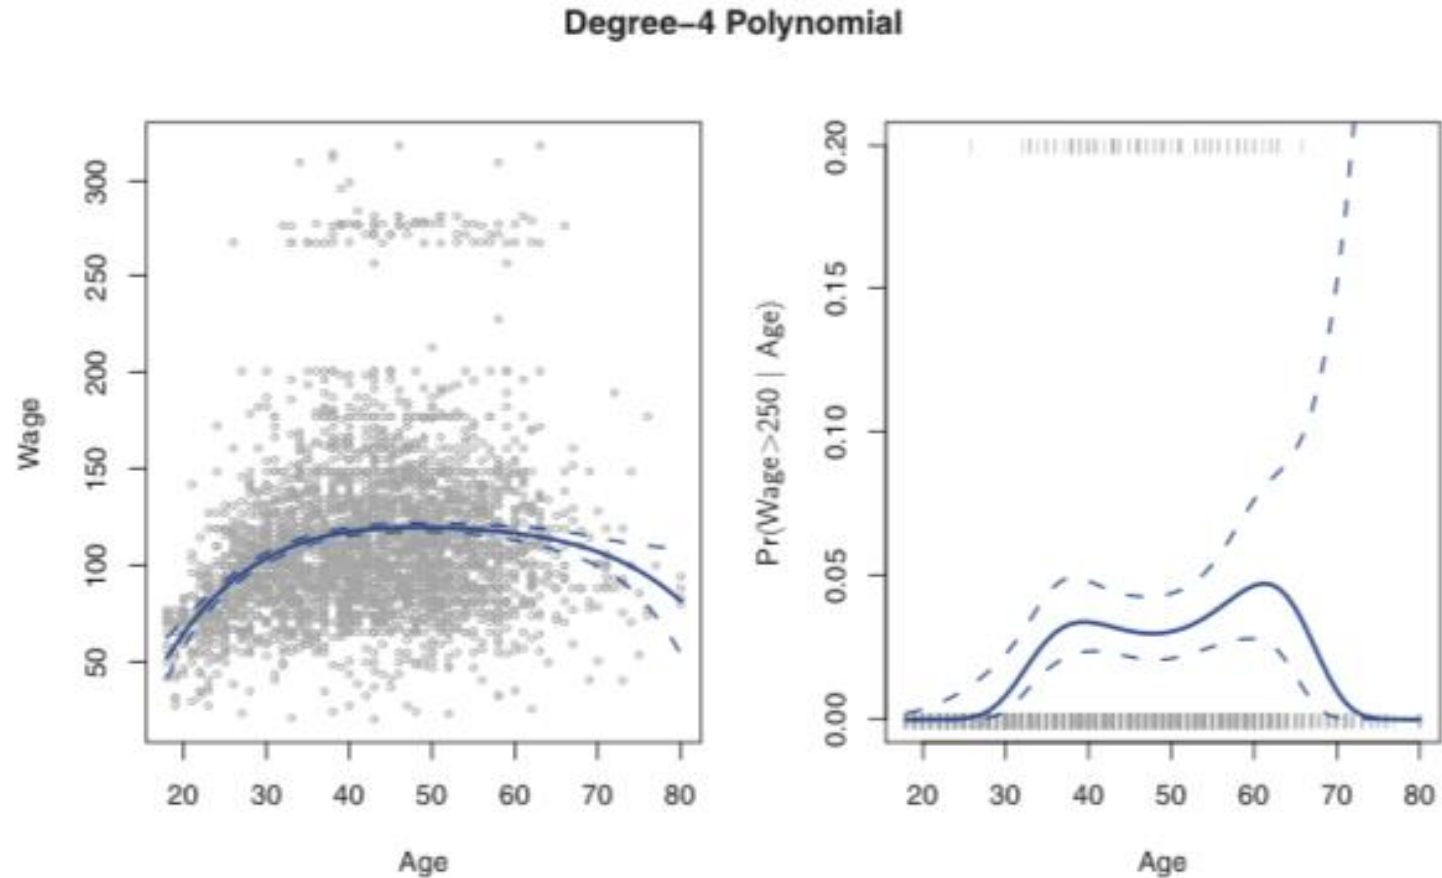


FIGURE 7.1. The **Wage** data. Left: The solid blue curve is a degree-4 polynomial of **wage** (in thousands of dollars) as a function of **age**, fit by least squares. The dotted curves indicate an estimated 95 % confidence interval. Right: We model the binary event **wage**>250 using logistic regression, again with a degree-4 polynomial. The fitted posterior probability of **wage** exceeding \$250,000 is shown in blue, along with an estimated 95 % confidence interval.

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Os modelos de regressão polinomial ou em nível são casos especiais de **basis functions**, em que se aplica uma determinada função ou transformação a uma variável x .*

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Ou seja, ao invés de ajustar um modelo linear a x , nós ajustamos um modelo linear a $b_1(x), b_2(x), \dots, b_k(x)$

$$y_i = \beta_0 + \beta_1 b_1(x_i) + \beta_2 b_2(x_i) + \dots + \beta_k b_k(x_i) + \varepsilon_i \quad (7.7)$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



As funções
 $b_1(\cdot), b_2(\cdot), \dots, b_k(\cdot)$
foram escolhidas
arbitrariamente
ANTES de
rodarmos o
modelo.

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



Nas duas sessões anteriores escolhemos a *função polinomial* e a *step function* para aplicar na variável x .

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



*Mas podemos
usar várias
outras **basis**
functions!!!*

1. Introdução

**2. Regressão
Polinomial**

3. Step Functions

4. Splines

5. Local Regression

**6. Generalize
Additive Models**



Que tal conhecermos uma nova função que vai nos dar ainda mais flexibilidade para rodar nossas regressões sem perder a capacidade de fazer inferências usando as mesmas ferramentas para calcular o desvio-padrão das estimativas e a estatística-F?!

1. Introdução

**2. Regressão
Polinomial**

3. Step Functions

4. Splines

5. Local Regression

**6. Generalize
Additive Models**



1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



SPLINES

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Vamos novamente particionar o intervalo de x . Mas, ao invés de usar uma função constante, vamos aplicar uma função polinomial cúbica. Para simplificar, vamos separar x em apenas duas partes.

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Na prática, vamos ajustar duas funções polinomiais de grau 3 aos dados. Uma função para os valores de x menores que c e outra para x maior que c , onde c é o **knot**.*

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Na prática, vamos ajustar duas funções polinomiais de grau 3 aos dados. Uma função para os valores de x menores que c e outra para x maior que c , onde c é o **knot**.*

$$y_i =$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Na prática, vamos ajustar duas funções polinomiais de grau 3 aos dados. Uma função para os valores de x menores que c e outra para x maior que c , onde c é o **knot**.*

$$y_i = \beta_{01} + \beta_{11}x_i + \beta_{21}x_i^2 + \beta_{31}x_i^3 + \varepsilon_i$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Na prática, vamos ajustar duas funções polinomiais de grau 3 aos dados. Uma função para os valores de x menores que c e outra para x maior que c , onde c é o **knot**.*

$$y_i = \beta_{01} + \beta_{11}x_i + \beta_{21}x_i^2 + \beta_{31}x_i^3 + \varepsilon_i, \text{ se } x_i < c$$

1. Introdução

2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models

*Na prática, vamos ajustar duas funções polinomiais de grau 3 aos dados. Uma função para os valores de x menores que c e outra para x maior que c , onde c é o **knot**.*

$$y_i = \begin{cases} \beta_{01} + \beta_{11}x_i + \beta_{21}x_i^2 + \beta_{31}x_i^3 + \varepsilon_i, & \text{se } x_i < c \\ \beta_{02} + \beta_{12}x_i + \beta_{22}x_i^2 + \beta_{32}x_i^3 + \varepsilon_i, & \text{se } x_i \geq c \end{cases}$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Na prática, vamos ajustar duas funções polinomiais de grau 3 aos dados. Uma função para os valores de x menores que c e outra para x maior que c , onde c é o **knot**.*

$$y_i = \begin{cases} \beta_{01} + \beta_{11}x_i + \beta_{21}x_i^2 + \beta_{31}x_i^3 + \varepsilon_i, & \text{se } x_i < c \\ \beta_{02} + \beta_{12}x_i + \beta_{22}x_i^2 + \beta_{32}x_i^3 + \varepsilon_i, & \text{se } x_i \geq c \end{cases}$$

1. Introdução

2. Regressão Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models

*Na prática, vamos ajustar duas funções polinomiais de grau 3 aos dados. Uma função para os valores de x menores que c e outra para x maior que c , onde c é o **knot**.*

$$y_i = \begin{cases} \beta_{01} + \beta_{11}x_i + \beta_{21}x_i^2 + \beta_{31}x_i^3 + \varepsilon_i, & \text{se } x_i < c \\ \beta_{02} + \beta_{12}x_i + \beta_{22}x_i^2 + \beta_{32}x_i^3 + \varepsilon_i, & \text{se } x_i \geq c \end{cases}$$

1. Introdução


2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



1. Introdução

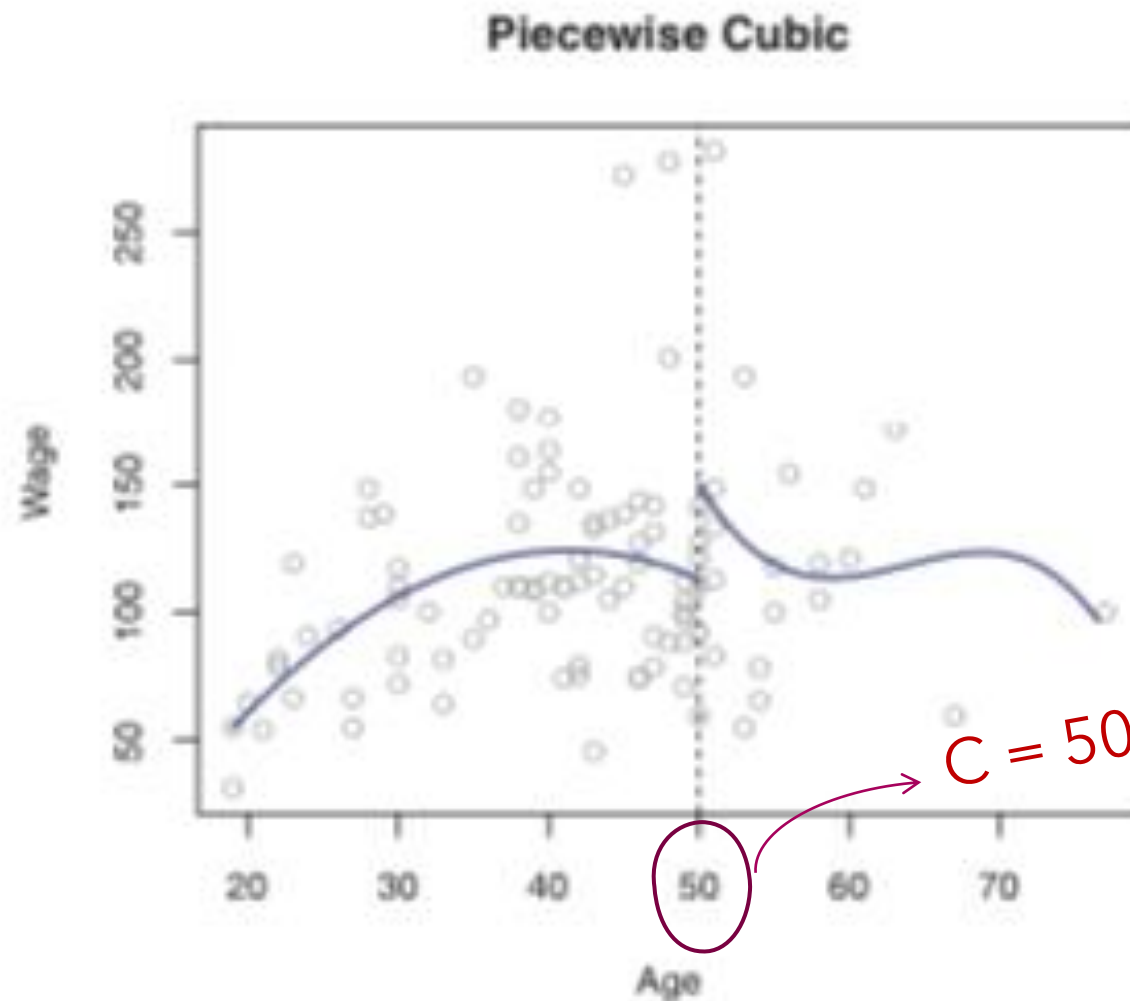
2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



1. Introdução

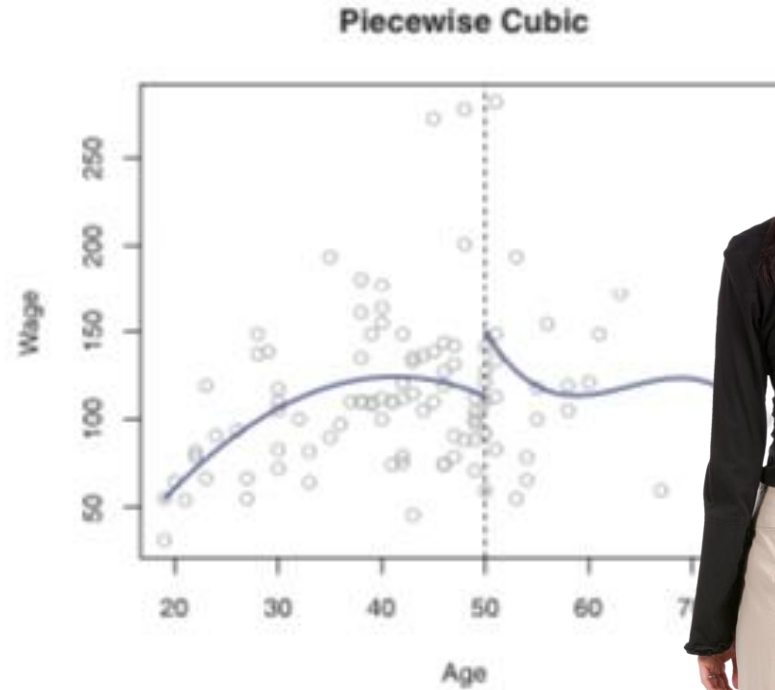
2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



1. Introdução


2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



Para resolver a questão da descontinuidade, podemos acrescentar uma restrição de que a primeira derivada no ponto C seja igual nas duas regressões. Vamos ver como fica?

1. Introdução


**2. Regressão
Polinomial**

3. Step Functions

4. Splines

5. Local Regression

**6. Generalize
Additive Models**



1. Introdução

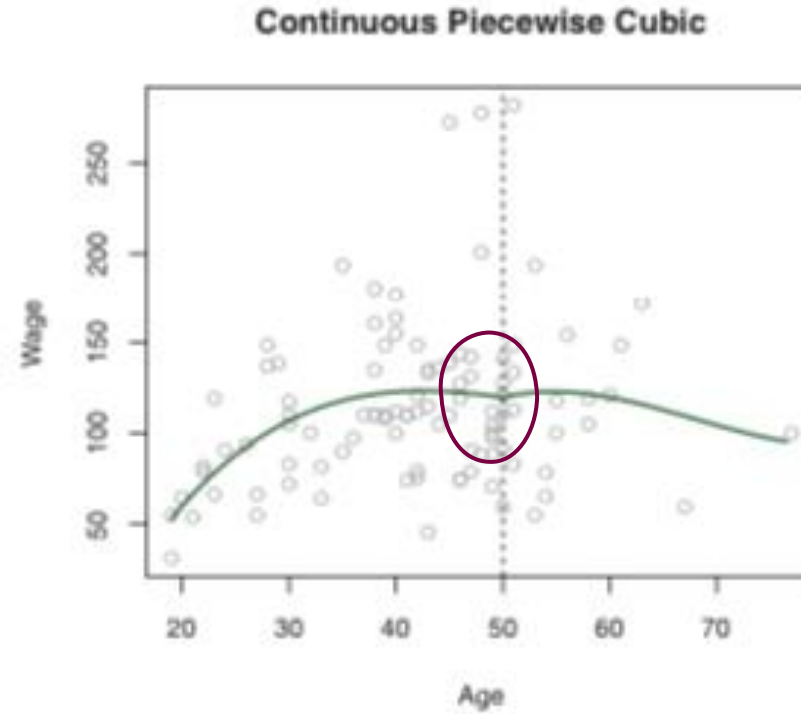
2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models



1. Introdução


2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



*Eliminamos o problema da descontinuidade, mas a curva tem um **bico**, formando um V no Knot..*

1. Introdução

**2. Regressão
Polinomial**

3. Step Functions

4. Splines

5. Local Regression

**6. Generalize
Additive Models**



Será que dá para melhorar?

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



*Será que dá para melhorar?
Será que podemos suavizar
mais a curva?*

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



*Será que dá para melhorar?
Será que podemos suavizar
mais a curva?
E se adicionássemos mais
uma restrição?*

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



*Será que dá para melhorar?
Será que podemos suavizar
mais a curva?*

*E se adicionássemos mais
uma restrição?*

*E se a **segunda derivada** no
ponto $c=50$ também tivesse
que ser igual nas duas
curvas?*

1. Introdução


**2. Regressão
Polinomial**

3. Step Functions

4. Splines

5. Local Regression

**6. Generalize
Additive Models**



1. Introdução


2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generilize
Additive Models



→ *Sem restrição*

1. Introdução

2. Regressão Polinomial



3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models

Primeira derivada em $x=50$ igual nas duas curvas



1. Introdução

2. Regressão Polinomial


3. Step Functions

4. Splines

5. Local Regression

6. Generalize Additive Models


Primeira derivada em $x=50$ igual nas duas curvas




Sem restrição

Segunda derivada em $x=50$ igual nas duas curvas

Continuous Piecewise Cubic



Cubic Spline



1. Introdução

**2. Regressão
Polinomial**

3. Step Functions

4. Splines

5. Local Regression

**6. Generalize
Additive Models**



Resumidamente,
conseguimos obter:

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



Resumidamente,
consequimos obter:

Flexibilidade

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



Resumidamente,
conseguimos obter:

Flexibilidade

Continuidade

1. Introdução

**2. Regressão
Polinomial**

3. Step Functions

4. Splines

5. Local Regression

**6. Generalize
Additive Models**



Resumidamente,
conseguimos obter:

Flexibilidade

Continuidade

Suavidade

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Agora, podemos generalizar
nosso modelo de **cubic splines**
para k knots.*

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \beta_4 b(x_i) + \dots + \beta_{k+3} b_{k+3}(x_i) + \varepsilon_i \quad (7.9)$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



$K + 4$ parâmetros?

*Da onde veio essa
equação?*

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



A equação 7.9 veio da equação genérica de *basis function* que já vimos. Nós aplicamos uma função ou transformação a x_i e calculamos um parâmetro β para cada fator $b(x_i)$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Recapitulando

Ou seja, ao invés de ajustar um modelo linear a x , nós ajustamos um modelo linear a $b_1(x), b_2(x), \dots, b_k(x)$

$$y_i = \beta_0 + \beta_1 b_1(x_i) + \beta_2 b_2(x_i) + \dots + \beta_k b_k(x_i) + \varepsilon_i \quad (7.7)$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Recapitulando

Ou seja, ao invés de ajustar um modelo linear a x , nós ajustamos um modelo linear a $b_1(x), b_2(x), \dots, b_k(x)$

$$y_i = \beta_0 + \beta_1 b_1(x_i) + \beta_2 b_2(x_i) + \dots + \beta_k b_k(x_i) + \varepsilon_i \quad (7.7)$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Recapitulando

Ou seja, ao invés de ajustar um modelo linear a x , nós ajustamos um modelo linear a $b_1(x), b_2(x), \dots, b_k(x)$

$$y_i = \beta_0 + \beta_1 b_1(x_i) + \beta_2 b_2(x_i) + \dots + \beta_k b_k(x_i) + \varepsilon_i \quad (7.7)$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Recapitulando

Ou seja, ao invés de ajustar um modelo linear a x , nós ajustamos um modelo linear a $b_1(x), b_2(x), \dots, b_k(x)$

$$y_i = \beta_0 + \beta_1 b_1(x_i) + \beta_2 b_2(x_i) + \dots + \beta_k b_k(x_i) + \varepsilon_i \quad (7.7)$$

$\rightarrow b_1(x_i) = x_i$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Recapitulando

Ou seja, ao invés de ajustar um modelo linear a x , nós ajustamos um modelo linear a $b_1(x), b_2(x), \dots, b_k(x)$

$$y_i = \beta_0 + \beta_1 b_1(x_i) + \beta_2 b_2(x_i) + \dots + \beta_k b_k(x_i) + \varepsilon_i \quad (7.7)$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Recapitulando

Ou seja, ao invés de ajustar um modelo linear a x , nós ajustamos um modelo linear a $b_1(x), b_2(x), \dots, b_k(x)$

$$y_i = \beta_0 + \beta_1 b_1(x_i) + \beta_2 b_2(x_i) + \dots + \beta_k b_k(x_i) + \varepsilon_i \quad (7.7)$$

$\rightarrow b_2(x_i) = x_i^2$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



*Além disso, se quisermos colocar k cortes no intervalo de x , teremos que colocar uma **restrição** em cada um desses knots para garantir que a curva que vamos ajustar aos dados será suave e contínua.*

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



As k restrições são funções de x_i . Para cada uma delas, vamos estimar um parâmetro. Além dessas k funções, temos no caso da cubic spline a constante β_0 , o parâmetro β_1 de x_i , β_2 de x_i^2 e β_3 de x_i^3 .

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Vamos ver novamente nossa
equação da cubic spline com k
knots*

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Vamos ver novamente nossa
equação da cubic spline com k
knots*

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \beta_4 b(x_i) + \dots + \beta_{k+3} b_{k+3}(x_i) + \varepsilon_i \quad (7.9)$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Vamos ver novamente nossa
equação da cubic spline com k
knots*

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \beta_4 b(x_i) + \dots + \beta_{k+3} b_{k+3}(x_i) + \varepsilon_i \quad (7.9)$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Vamos ver novamente nossa
equação da cubic spline com k
knots*

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \beta_4 b(x_i) + \dots + \beta_{k+3} b_{k+3}(x_i) + \varepsilon_i \quad (7.9)$$

4

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Vamos ver novamente nossa
equação da cubic spline com k
knots*

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \beta_4 b(x_i) + \dots + \beta_{k+3} b_{k+3}(x_i) + \varepsilon_i \quad (7.9)$$

4

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Vamos ver novamente nossa
equação da cubic spline com k
knots*

$$y_i = \underbrace{\beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3}_{4} + \underbrace{\beta_4 b(x_i) + \dots + \beta_{k+3} b_{k+3}(x_i)}_k + \varepsilon_i \quad (7.9)$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Falta ainda determinar as k
funções para garantir a
continuidade da curva nos k
pontos de corte de maneira suave*

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \underbrace{\beta_4 b_4(x_i) + \dots + \beta_{k+3} b_{k+3}(x_i)}_k + \varepsilon_i \quad (7.9)$$

k

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

Tínhamos visto que forçar a primeira e a segunda derivadas no knot era capaz de gerar uma curva contínua e suave.

Vamos ver agora uma outra forma para gerar esses resultados com uma única restrição em vez de duas para cada ponto k .

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

A função “truncated power” pode ser definida como

$$h(x, \xi) = \begin{cases} (x - \xi)^3, & \text{se } x > \xi \\ 0 & , \text{ caso contrário} \end{cases}$$

onde ξ é o valor do knot. No caso do polinômio de terceiro grau a função $h(.)$ vai gerar continuidade da primeira e segunda derivada.

1. Introdução

**2. Regressão
Polinomial**

3. Step Functions

4. Splines

5. Local Regression

**6. Generalized
Additive Models**



Considerações Importantes:

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalized
Additive Models



Considerações Importantes:

Para flexibilizar a hipótese de linearidade podemos recorrer a uma regressão polinomial de grau d ou a uma Spline

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalized
Additive Models



Considerações Importantes:

No entanto, para dar mais flexibilidade ao modelo polinomial, é necessário aumentar bastante a potência e isso gera parâmetros mais instáveis.

1. Introdução

**2. Regressão
Polinomial**

3. Step Functions

4. Splines

5. Local Regression

**6. Generalized
Additive Models**



Considerações Importantes:

Ao mesmo tempo, a Cubic Splines consegue trazer a flexibilidade desejada aumentando a quantidade de knots.

1. Introdução

**2. Regressão
Polinomial**

3. Step Functions

4. Splines

5. Local Regression

**6. Generalized
Additive Models**



Considerações Importantes:

Mais especificamente, basta acrescentar mais knots nas regiões que apresentam mais variações no comportamento.

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



1º) Pegamos nosso modelo
linear clássico $y = \beta_0 - \beta_1 x$ e
acrescentamos x^2 e x^3

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



1º) Pegamos nosso modelo
linear clássico $y = \beta_0 + \beta_1 x$ e
acrescentamos x^2 e x^3

$$\underline{y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3}$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



*2º) Para dar mais flexibilidade,
dividimos o intervalo x em k
knots*

1. Introdução

2. Regressão
Polinomial

3. Step Functions


4. Splines

5. Local Regression

6. Generalize
Additive Models



2º) Para dar mais flexibilidade,
dividimos o intervalo x em k
knots



1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models



3º) Para cada pedaço do intervalo X , formado pelos k knots, impõe-se uma trunked function que garante a continuidade e suavidade das cubic splines

$$h(x, \xi) = \begin{cases} (x - \xi)^3, & \text{se } x > \xi \\ 0 & , \text{ caso contrário} \end{cases}$$

1. Introdução

2. Regressão
Polinomial

3. Step Functions

4. Splines

5. Local Regression

6. Generalize
Additive Models

*Agora, podemos generalizar
nosso modelo de **cubic splines**
para k knots.*

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \beta_4 h(x_i, \xi_1) + \dots + \beta_{k+3} h(x_i, \xi_k) + \varepsilon_i$$